AI 판단 지원과 독립 수행 자기평가 연구 제안서 (통합본)

Nov 4, 2026 · @조항민

> **연구의 핵심 질문**
>
> AI의 추천과 설명 덕분에 선택이 쉬워졌을 때, 사용자는 이후 AI 없이 바뀐 조건에 판단을 적용하는 자신의 수행을 적절하게 예상하는가?

이 연구는 AI 판단 지원 있음/없음의 두 집단과, 서로 다른 원리를 쓰는 **CRT형 문제 묶음 세 개**라는 구조를 사용한다. 아래 문항은 파일럿용 자극안이다. 정답은 코드로 검산했고, 난이도와 채점 일관성은 파일럿에서 확인한 뒤 본 실험용으로 고정한다.

이번 판에서 바뀐 점 (2026년 11월)

지도교수 피드백(교환학생 시나리오가 지나치게 구체적이므로 더 일반적인 CRT 문제로 바꾸는 것이 좋겠다)과 대학원생 피드백(자기효능감 개념 적용)을 반영했다.

영역	이전 판	이번 판
과제	교환학생 학교 선택 사례 3개(후보 4개)	CRT형 문제 묶음 3개: 차이, 비율, 거래 손익 (6장)
문항 구성	사례마다 적용 2 + 설명 2	묶음마다 적용 3(함정 없는 문항 1개 포함) + 설명 2
예상 점수	적용 0~4, 설명 0~4	적용 0~6, 설명 0~4
자기효능감	없음	과제 자기효능감 확신도 1문항(0~100), 보조 지표
연습 과제	스터디룸 선택	왕복 평균 속력 (CRT형, 본 과제와 다른 원리)
관련 연구	이해의 착각, 의존 행동, 자기평가	추가: AI 지원 방식과 CRT(Nair et al., 2025), AI를 치운 뒤의 수행, 자기효능감
표본	48명 목표, 36명 최소선	30명 목표, 24명 최소선 + 모집 부족 시 단계별 대응 (14장)
소요 시간	35~45분	20~30분
데이터 수집	브라우저 저장 후 내려받기	서버 자동 수집 (대면·비대면 공통)

1. 문제제기

생성형 AI는 자료 요약을 넘어 여러 조건을 비교하고, 우선순위를 정하고, 최종 추천과 그 이유까지 제공한다. 사용자는 이 지원으로 복잡한 문제를 더 적은 노력으로 해결할 수 있다. 그러나 다음 두 가지는 구분해야 한다.

- **AI의 도움을 받아 적절한 선택을 하는 것**
- **AI의 해석 없이 선택 이유를 설명하고, 조건이 달라졌을 때 다시 판단하는 것**

사용자가 이 두 수행의 차이를 스스로 알아차리는지도 별개의 문제다. AI 설명을 읽고 "이해했다"고 느꼈지만 조건이 바뀌면 제대로 적용하지 못할 수 있다. 반대로 AI 설명에서 핵심 관계를 배워 이후 수행이 좋아질 수도 있다.

따라서 이 연구는 AI가 이해를 약화한다고 전제하지 않는다.

> **AI 판단 지원이 이후의 독립 수행과, 그 수행에 대한 자기평가를 어떻게 바꾸는지 확인한다.**

2. 관련 연구와 차별점

본 연구는 다섯 연구 흐름이 만나는 지점에 있다. 설명을 받으면 이해했다고 느끼는 경향, AI 설명이 의존 행동을 바꾸는 방식, AI를 치운 뒤의 수행, 자기평가와 자기효능감, 그리고 CRT를 사용한 AI 지원 연구다.

설명이 만드는 '이해했다는 느낌'

사람들은 일상적 대상의 작동 원리를 실제보다 잘 안다고 평가하며, 직접 설명해 보라고 하면 그 평가를 낮춘다. 이를 설명적 깊이의 착각이라 한다(Rozenblit & Keil, 2002). 인터넷 검색으로 설명을 찾은 사람은 검색과 무관한 주제에서도 자기 지식을 더 높게 평가했다(Fisher, Goddu, & Keil, 2015).

이 착각은 XAI에서도 확인되었다. 국소적 AI 설명을 본 사용자는 모델을 이해했다고 평가했지만, 실제 이해도 검사 후에는 그 평가를 낮추었다(Chromik et al., 2021).

AI 설명과 의존 행동

AI 설명은 사용자가 AI를 맞을 때나 틀릴 때나 따르게 만들 수 있다(Bansal et al., 2021). 사용자가 스스로 생각하도록 강제하는 인터페이스는 과의존을 줄였지만 주관적 만족도도 낮추었다(Buçinca, Malaya, & Gajos, 2021). 설명이 과의존을 줄이는지는 과제 난이도와 설명 검토 비용에 따라 달라진다는 비용-편익 설명도 있다(Vasconcelos et al., 2023).

AI 지원을 주는 방식도 의존을 바꾼다. Nair 등(2025)은 대학생 232명에게 CRT 7문항과 수학 5문항을 풀게 하면서, 미리 작성한(항상 틀린) AI 추천과 설명을 자동으로 보여주는 집단, 요청할 때만 보여주는 집단, AI 없는 집단을 비교했다. 자동으로 받은 집단이 틀린 AI를 가장 많이 따랐고, 스스로 먼저 답을 정한 참가자는 AI에 덜 흔들렸다. 다만 CRT 점수는 세 집단 사이에 유의한 차이가 없었고($p = .26$), 차이는 수

학 문항에서만 나타났다. 저자들은 CRT 자체의 함정이 커서 AI 영향이 묻혔을 것이라고 해석했다. 이 연구는 본 연구에 두 가지 근거를 준다. CRT형 문제가 AI 지원 실험의 과제로 쓰일 수 있다는 점, 그리고 미리 검수한 AI 응답으로 모든 참가자에게 같은 지원을 주는 방식이다.

AI를 치운 뒤의 수행

AI 도움을 받을 때의 점수와, 이후 혼자 풀 때의 점수는 다를 수 있다. 고등학생 약 1,000명을 대상으로 한 현장 실험에서 일반 GPT로 수학을 연습한 집단은 연습 점수가 크게 올랐지만, AI 없이 본 시험에서는 AI를 쓰지 않은 집단보다 낮았고, 학생들은 그 차이를 느끼지 못했다(Bastani et al., 2025). AI의 추천과 설명을 함께 받은 참가자는 그 자리에서는 더 잘 풀었지만, AI 없이 푼 같은 개념의 새 문제에서는 배운 것이 거의 없었다(Gajos & Mamykina, 2022).

자기평가와 자기효능감

AI를 사용해 논리 추론 문제를 푼 참가자의 점수는 규준 집단보다 높았지만, 자기평가는 실제 점수를 더 크게 웃돌았다(Fernandes et al., 2026). 이 연구는 'AI 없이 풀었다면 몇 점일지'를 예상만 받고, 실제로 AI 없이 풀게 하지는 않았다. 자기평가 정확도는 방향성 오차(bias)와 절대오차, 그리고 판단이 실제 수행을 얼마나 잘 구별하는지(resolution)로 나누어 보아야 한다(Schraw, 2009).

자기효능감은 특정 과제를 해낼 수 있다는 자신의 능력에 대한 믿음이다(Bandura, 1977). Bandura(2006)는 일반적인 척도보다 과제에 맞춘 문항을 0~100 확신도로 묻는 방식을 권한다. 본 연구의 예상 점수는 이 과제 수준 자기효능감을 점수 단위로 물은 것이다. 자기효능감만으로는 믿음이 실제보다 높은지 알 수 없으므로, 주 지표는 같은 척도의 예상 점수와 실제 점수의 차이로 두고, 확신도 문항은 보조 지표로 쓴다.

본 연구의 차별점

선행연구가 본 것	본 연구가 보는 것
AI 모델이 어떻게 작동하는지에 대한 이해 (Chromik 등)	AI 없이 과제 자체를 다시 수행하는 능력에 대한 자기평가
AI를 사용하는 동안의 수행과 자기평가 (Fernandes 등)	AI를 치운 뒤 조건이 바뀐 문제의 실제 수행과 그 예상
AI 사용 중 틀린 추천을 따르는지 (Bansal, Nair 등)	AI가 맞는 설명을 준 뒤 남는 독립 수행과 자기평가의 차이
몇 주간 AI로 학습한 뒤의 시험과 사후 설문 (Bastani 등)	AI가 한 번 판단을 도운 직후, 풀기 전에 받은 예상 점수와 실제 점수의 직접 비교

AI를 쓴 뒤 혼자 하면 수행이 떨어지고 본인은 그것을 잘 모른다는 결과는 학습 상황에서 이미 보고되었다. 본 연구는 새로운 현상을 주장하지 않는다. 같은 현상이 AI가 판단을 한 번 도와주는 상황에서도 나타나는지, 예상 점수와 실제 점수를 같은 기준으로 비교해 확인한다.

3. 독립 수행의 정의

> 문제 원문과 공통 계산기를 참고하되, AI의 추천과 설명을 다시 보지 않고 조건이 바뀐 문제를 풀거나 원래 문제의 풀이 이유를 설명하는 수행.

이 연구가 측정하지 않는 것은 다음과 같다.

- 문제 원문을 보지 않고 기억하는 능력
- 장기적으로 남은 지식
- 일반적인 지능이나 수학 실력, 성찰적 사고 성향 자체
- AI 사용 전후의 개인 능력 감소
- 실제 환경에서 AI를 다시 활용하는 능력

CRT는 본래 개인의 성찰적 사고 성향을 재는 도구지만, 본 연구는 CRT형 문제를 성향 검사가 아니라 '처음 떠오른 답이 틀리기 쉬운 판단 과제'로 쓴다. 따라서 CRT 점수를 개인의 사고 성향으로 해석하지 않는다.

AI 설명에서 배운 관계를 기억해 새로운 문제에 정확히 적용했다면, 그것은 인정해야 할 성과다. 문제는 **평가 질문이 정답이나 결정적 조건을 대신 알려주어, 독립적으로 판단하지 않아도 높은 점수를 받는 경우**다. 이 연구는 문항 설계로 그 가능성을 줄인다.

4. 연구질문과 가설

주요 연구질문

RQ1. AI의 추천과 풀이 설명을 제공하면, 조건이 바뀐 문제에 대한 **예상 적용 점수와 실제 적용 점수 사이의 방향성 있는 차이**(`D_적용`)가 달라지는가?

보조 연구질문

RQ2. AI 판단 지원은 이후의 독립적인 적용·설명 수행에 어떤 영향을 주는가?

RQ3. AI 판단 지원은 최초 답 선택 단계의 정신적 부담을 줄이는가?

RQ4 (탐색). AI 판단 지원은 비슷한 문제를 혼자 풀 수 있다는 과제 자기효능감을 높이는가? 그 자기효능감은 실제 수행과 얼마나 함께 움직이는가?

가설

- H1: AI 판단 지원 집단은 지원 없는 집단보다 자기 점수를 실제보다 더 높게 예상할 것이다(`D_적용`이 높을 것이다).
- H2: AI 판단 지원 집단은 최초 답 선택 단계의 정신적 부담이 낮을 것이다.

- 실제 독립 수행이 향상될지 낮아질지, 자기효능감이 어느 방향으로 움직일지는 방향을 고정하지 않는다.

H1은 **자기평가가 높은 방향으로 이동한다는 예상**이지, 반드시 더 부정확해진다는 뜻은 아니다. 과소평가에서 정확한 평가로 이동할 수도 있다. 주요 분석은 반대 방향의 결과도 확인할 수 있도록 양측 검정을 사용한다. '이해의 착각'은 특정 결과를 해석하는 개념으로만 쓰고, 지표 이름으로 쓰지 않는다.

주 지표를 적용 문항으로 정한 이유

설명 문항은 B집단이 받은 AI 설명과 내용이 겹친다. 예를 들어 '원래 문제에서 답이 3,000원이 아닌 이유'는 AI가 이미 설명했다. 같은 점수라도 B집단에게는 기억 재생, A집단에게는 스스로 만든 추론이 된다. 설명 문항을 주 지표에 넣으면 B집단의 실제 점수가 기계적으로 올라가 H1과 반대 방향의 편향이 생긴다. 그래서 주 지표는 AI가 다루지 않은 적용 문항으로 계산하고, 설명 문항은 보조 지표로 보고한다.

5. 실험 설계와 배정

독립변수는 AI 판단 지원 제공 여부 하나다. 참가자 한 명은 A 또는 B 조건만 경험하는 집단 간 설계다. 같은 참가자가 두 조건을 모두 경험하면 AI 설명에서 배운 내용이 다음 조건으로 넘어가기 때문이다. 모집이 매우 어려울 때의 대안 설계는 14장에 따로 두었다.

요소	A: 판단 지원 없음	B: AI 판단 지원 있음
문제 원문과 4개 보기	동일	동일
공통 계산기	동일	동일
공통 연습과 기준 D 측정	동일	동일
AI의 추천 답	없음	제공
풀이 과정과 함정 답이 틀린 이유 설명	없음	제공
참가자의 최초 답 선택	수행	수행
이후 예상 점수·확신도·적용·설명 평가	동일	동일

실험이 추정하는 것은 **추천과 설명을 함께 추가한 지원 방식의 효과**다. AI라는 이름의 효과, 추천만의 효과, 설명만의 효과, 인간 조언자와의 차이는 분리하지 않는다. 실시간 LLM 대신 사전에 검수한 정확한 추천과 설명을 제공하며(Wizard of Oz), 참여 안내에서 미리 검수한 화면임을 밝힌다.

묶음 순서: 라틴 방진

모든 참가자가 세 묶음을 모두 풀기 때문에, 두 집단의 순서 분포만 같으면 순서는 집단 비교를 왜곡하지 않는다. 순서를 섞는 목적은 위치 효과(첫 묶음이라 어렵게 느낌, 앞 묶음에서 얻은 요령 등)가 특정 묶음에 쏠리지 않게 하는 것이다.

순서	1번째	2번째	3번째
순서 I	묶음 1 (차이)	묶음 2 (비율)	묶음 3 (손익)
순서 II	묶음 2 (비율)	묶음 3 (손익)	묶음 1 (차이)
순서 III	묶음 3 (손익)	묶음 1 (차이)	묶음 2 (비율)

각 묶음이 각 위치에 정확히 한 번씩 나온다. 두 집단 × 3개 순서 = **6개 운영 조합**이다. 6조합 실험이 아니라, 두 집단과 순서를 균형 있게 운영하기 위한 배정 단위다. 첫 번째 위치의 묶음은 요령이 쌓이기 전의 가장 깨끗한 비교라, 민감도 분석에 따로 쓴다(15장).

블록 무작위 배정

- 6개 조합을 한 블록으로 묶어 무작위로 섞은 배정표를 미리 만든다.
- 참가자가 도착(또는 링크 접속)하는 순서대로 배정표를 따른다.
- 블록 5개 = 30명이면 각 조합에 정확히 5명이 배정된다.
- 모집이 중간에 끊겨도 집단 간 차이는 최대 3명이다.
- 배정표는 참가자를 만나는 연구자가 미리 볼 수 없게 관리한다. 중도 이탈자의 자리는 새 참가자로 채우지 않고 다음 순번으로 넘어간다.

6. 과제 선정과 문항 설계

과제는 교환학생 학교 선택 시나리오에서 **CRT(Cognitive Reflection Test) 원리를 쓴 새 문제 묶음 세 개**로 바꾼다. CRT는 직관적으로 떠오르는 답이 틀리도록 만든 짧은 문제로, 처음 떠오른 답을 멈추고 다시 따져보는지를 본다(Frederick, 2005).

왜 CRT형 문제로 바꾸는가

이유	교환학생 시나리오의 문제	CRT형 문제로 바꾸면
결과의 일반성	특정 상황(교환학생)에서 나온 결과라 "그 소재에서만 그런 것 아닌가"라는 반론을 막기 어렵다	특정 상황과 경험에 묶이지 않는 일반적인 추론 문제다
과제의 근거	연구팀이 만든 문제라 난이도와 타당도의 근거가 약하다	20년 가까이 쓰인 과제 계열이고, AI 지원 실험에도 쓰였다(Nair et al., 2025)
채점	서술형 근거를 읽고 판단해야 해 채점자 해석이 들어간다	정답이 숫자 하나라 채점이 거의 객관적이다
문항 수	사례 하나에 읽을 자료가 많아 문항을 늘리기 어렵다	문항이 짧아 묶음마다 적용 문항을 3개로 늘릴 수 있다

이유	교환학생 시나리오의 문제	CRT형 문제로 바꾸면
연구 주제와의 일치	조건 비교 판단이라 설명을 들어도 '아하' 느낌이 약하다	설명을 들으면 "아, 그렇구나" 하는 이해의 느낌이 강하게 온다. 이 느낌이 본 연구가 보려는 대상이다

잃는 것도 있다. 교환학생 시나리오는 여러 조건을 비교해 고르는 실제 AI 사용 장면에 더 가까웠고, CRT형 문제는 퍼즐에 가깝다. 이 차이는 17장 한계에 적는다.

왜 CRT 원문을 그대로 쓰지 않는가

1. **널리 알려진 문항이다.** 공과 방망이 문제는 대중서에도 소개되어 대학생 상당수가 알고 있다. CRT 문항을 본 적 있는 사람은 점수가 높았다(d = 0.57; Bialek & Pennycook, 2018). 그래서 원리만 빌리고 소재와 숫자는 새로 만든다.
2. **설명 한 번이면 요령이 풀린다.** AI가 원리를 설명하면 숫자만 바꾼 문제는 B집단이 거의 다 맞힐 수 있다. 그래서 적용 문항에 구조를 바꾼 문제와 함정이 없는 문제를 섞어, 요령만 외운 사람과 원리를 이해한 사람을 구분한다.
3. **CRT 원문에서는 AI 효과가 잘 보이지 않았다.** Nair 등(2025)에서 CRT 점수는 집단 차이가 없었다. 본 연구는 CRT 원문의 점수가 아니라, 설명을 들은 뒤 바뀐 조건에 적용하는 수행과 그 예상을 본다.

왜 이 세 묶음인가

묶음	원리 (CRT의 대표 문항)	떠오르기 쉬운 함정	풀기 위해 필요한 것
1. 차이	두 값의 합과 차이 (공과 방망이; Frederick, 2005)	합에서 차이를 그냥 뺀다	미지수 하나를 두고 식을 세운다
2. 비율	일하는 수와 작업량 (기계와 부품; Frederick, 2005)	숫자를 비례식처럼 그대로 따라간다	한 대가 단위 시간에 하는 양을 구한다
3. 손익	연속 거래의 이익 (돼지 매매; Toplak et al., 2014)	다시 비싸게 산 것을 손해로 셈한다	거래를 따로 계산하거나 들어오고 나간 돈을 더한다

- **원리가 서로 다르다.** 한 묶음에서 배운 풀이법이 다른 묶음의 답을 알려주지 않는다. 교환학생 시나리오의 사례 1과 3이 '걸러낸 뒤 비교'라는 풀이 구조를 공유하던 문제를 줄인다.
- **적용 문항을 만들기 쉽다.** 숫자를 바꾸거나 관계 하나를 바꾸면 답이 달라지는 문제와 유지되는 문제를 모두 만들 수 있다.
- **수학 실력에 덜 의존한다.** 중학교 수준의 사칙연산과 일차식으로 풀리며, 계산기를 제공한다.
- **소재는 일상적이다.** 과일 상자, 프린터, 중고 카메라처럼 전문지식이 필요 없는 소재를 쓴다.
- 파일럿에서 어느 묶음이 천장에 붙거나 노출이 심하면, 예비 묶음(매일 2배로 늘어나는 양; Frederick, 2005의 연잎 문항 원리)으로 교체한다.

묶음의 구성

단계	내용	배점
원 문제	4지선다. 함정 답이 보기에 포함된다. B집단은 여기서 AI 추천과 설명을 본다	채점하지 않음 (최초 선택 정답 여부만 기록)
적용 a: 숫자 변경	구조는 같고 숫자만 바뀜. 함정이 남아 있다	0~2점
적용 b: 구조 변경	관계 하나가 바뀜. 원 문제의 풀이를 그대로 옮겨서는 틀린다	0~2점
적용 c: 함정 없음	처음 떠오르는 답이 그대로 정답인 문제. '일단 의심하고 반대로' 하는 요령을 걸러낸다(De Neys et al., 2013의 비갈등 문항 방식)	0~2점
설명 1	원 문제에서 함정 답이 틀린 이유	0~2점
설명 2	원 문제의 관계가 바뀌면 답이 어느 방향으로 움직이는지	0~2점

- 묶음마다 **적용 6점, 설명 4점**이다.
- 적용 문항 a·b·c의 제시 순서는 참가자마다 무작위로 섞고, 설명 문항은 적용 문항 다음에 둔다. 설명을 먼저 쓰면 적용 문항의 힌트가 되기 때문이다.
- 적용·설명 문항은 숫자 답과 풀이를 적는 주관식이다. 보기를 주지 않아 찍어서 맞힐 수 없다.

문항 원칙

- 답이 바뀌는 문제와 유지되는 문제를 모두 포함한다.
- 각 적용 문항은 원 문제에서 독립적으로 출발한다. 앞 문항의 변경은 이어지지 않는다.
- 문항 표현에 풀이 방법이나 함정을 암시하지 않는다(예: "주의하세요", "함정이 있습니다").
- 평가 도중 정답 피드백을 제공하지 않는다.
- 설명 문항의 점수를 '원리를 스스로 발견한 능력'으로 과장하지 않는다.

정답 배치

묶음	원 문제 정답 (함정)	적용 a: 숫자 변경	적용 b: 구조 변경	적용 c: 함정 없음
1. 차이	1,500원 (3,000원)	1,500원 (유지)	10,000원 (변경)	3,000원 (변경)
2. 비율	3분 (30분)	3분 (유지)	9분 (변경)	6분 (변경)
3. 손익	20만 원 (10만 원)	20만 원 (유지)	5만 원 (변경)	20만 원 (유지)

- 적용 c의 답은 묶음 1에서 원 문제의 함정 답(3,000원)과 같다. "처음 떠오른 답은 항상 틀린다"는 요령을 쓰면 오히려 틀리게 된다.
- 유지 문항은 원래 답을 그대로 써도 숫자는 맞는다. 그래서 2점에는 바뀐 숫자로 다시 계산한 풀이를 요구한다.
- 원 문제 4개 보기의 순서는 참가자마다 섞는다.

묶음 사이에 요령이 넘어가는 문제

원리가 달라도 "이 실험의 문제는 처음 떠오른 답이 틀리는구나"라는 감은 다음 묶음으로 넘어간다. 특히 B집단은 첫 묶음에서 AI가 "직관적인 답은 틀립니다"라고 설명하므로 이를 더 빨리 알아챌 수 있다. 이에 네 가지로 대응한다.

1. **함정 없는 문항(적용 c)**을 섞어, 일단 의심하는 요령만으로는 점수를 얻지 못하게 한다.
2. **공통 연습에서 두 집단 모두 CRT형 문제와 풀이를 먼저 경험**한다(7장). '함정이 있을 수 있다'는 감을 두 집단이 같은 수준에서 시작한다.
3. **첫 번째 묶음만으로 따로 비교**한다. 요령이 쌓이기 전의 가장 깨끗한 비교다.
4. **위치별로 확인**한다. 1·2·3번째 묶음에서 집단 차이가 커진다면, 그 자체를 'AI 설명이 문제 너머의 요령까지 알려준다'는 탐색적 발견으로 보고한다.

7. 공통 연습 과제와 기준 D 측정

연습 과제는 세 가지 역할을 한다. 답변 형식과 채점 방식을 익히게 하고, AI 지원을 받기 전 각 참가자의 원래 자기평가 성향(기준 D)을 측정하며, 두 집단이 'CRT형 문제에는 함정이 있을 수 있다'는 감을 같은 수준에서 갖고 본 과제를 시작하게 한다. 두 집단 모두 AI 없이 똑같이 수행한다.

왜 기준 D가 필요한가

원래 자신감이 높거나 낮은 사람은 있다. 무작위 배정은 이런 성향을 두 집단에 평균적으로 고르게 나누지만, 집단당 15명 규모에서는 우연히 한쪽에 몰릴 수 있다. 기준 D는 (1) 두 집단이 비슷하게 배정되었는지 확인하고, (2) 분석에서 원래 성향을 보정해 같은 인원으로 더 정밀한 추정을 가능하게 한다.

연습 문제: 왕복 평균 속력 (참가자 화면)

본 과제의 세 묶음과 원리가 다른 CRT형 문제를 쓴다. 연습에서 배운 풀이가 본 과제의 답을 알려주지 않게 하기 위해서다.

> 같은 길로 도서관까지 갈 때는 시속 6km, 돌아올 때는 시속 3km로 걸었습니다. 왕복 전체의 평균 속력은 시속 몇 km입니까?
>
> ① 3km ② 4km ③ 4.5km ④ 6km

정답은 **시속 4km**다. 편도 거리를 6km로 두면 갈 때 1시간, 올 때 2시간이므로 12km ÷ 3시간 = 4km다. 함정 답은 두 속력의 단순 평균인 4.5km다.

연습 절차

1. 원 문제의 답을 고른다.
2. 본 과제와 같은 화면에서 과제 확신도(0~100)와 적용 예상 점수(0~6)를 입력한다.
3. 적용 3문항과 설명 1문항에 답한다.
4. 모두 제출한 뒤에 정답, 풀이, 채점 예시를 본다.

예상 점수 입력과 답변이 피드백보다 먼저 이루어지므로, 기준 D는 피드백의 영향을 받지 않는다. 연습에는 설명 예상 칸을 두지 않고, 본 과제에서는 설명 예상 칸이 하나 더 있다고 안내한다.

연습 문항

번호	문항	정답	함정 답
P-1 적용 (숫자 변경)	"갈 때는 시속 12km, 돌아올 때는 시속 4km라면 왕복 평균 속력은? 답과 풀이를 쓰세요."	시속 6km (편도 12km: 1시간 + 3시간, 24km ÷ 4시간)	8km
P-2 적용 (함정 없음)	"갈 때와 돌아올 때 모두 시속 5km로 걸었다면 왕복 평균 속력은?"	시속 5km	없음
P-3 적용 (구조 변경)	"처음 1시간은 시속 6km, 다음 1시간은 시속 3km로 걸었다면 2시간 전체의 평균 속력은?"	시속 4.5km (9km ÷ 2시간. 시간이 같으면 단순 평균이 맞다)	4km (원 문제의 답을 그대로 옮김)
P-4 설명	"원래 문제에서 답이 4.5km가 아닌 이유를 설명하세요."	느린 속력으로 걷는 시간이 더 길기 때문. 편도 6km면 12km를 3시간에 간다	—

기준 D 계산

$$D_{\text{기준}} = \text{연습 적용 예상 점수}(0\sim6) - \text{연습 적용 실제 점수}(0\sim6)$$

- 기준 D는 주 지표와 같은 적용 문항 기준, 같은 6점 척도로 계산한다.
- 연습 적용 답변(참가자당 3개)도 본 과제와 같은 채점자, 같은 블라인드 절차로 채점한다.
- 연습 확신도는 기준 자기효능감(SE_기준)으로 저장한다.
- 연습 설명 답변은 형식 연습용이며 채점하지 않는다.

채점 예시 (제출 후 두 집단에 동일하게 제시)

예시 답변 (P-1)	점수	이유
"6km. 편도 12km면 갈 때 1시간, 올 때 3시간. 24km ÷ 4시간 = 6"	2점	정답과 풀이가 모두 맞음
"6km"	1점	정답이지만 풀이가 없음
"8km. (12 + 4) ÷ 2"	0점	두 속력을 단순 평균한 함정 답

연습에서는 다음을 강조한다.

- 길게 쓰는 것이 목표가 아니다. 짧은 식과 계산이면 충분하다.
- 답만 맞고 풀이가 없으면 부분점수가 된다.
- 모르겠으면 '모르겠음'을 선택할 수 있다.
- 예상 점수는 방금 고른 답에 대한 자신감이 아니라 이후 문항의 점수 예상이다.

8. 묶음 1: 차이 문제 (사과 상자와 배 상자)

정답은 **1,500원**이다. 합(33,000원)에서 차이(30,000원)를 그냥 빼면 3,000원이 떠오르지만, 그러면 두 상자의 합이 36,000원이 된다. CRT의 공과 방망이 문항과 같은 원리다.

원 문제 (참가자 화면)

> 사과 한 상자와 배 한 상자를 합쳐 33,000원입니다. 사과 상자는 배 상자보다 30,000원 비쌉니다. 배 상자는 얼마입니까?
>
> ① 1,500원 ② 3,000원 ③ 16,500원 ④ 30,000원

연구자용 검산

배 상자를 x원이라 하면 사과 상자는 x + 30,000원이다. 2x + 30,000 = 33,000이므로 x = 1,500원, 사과 상자는 31,500원이다.

함정 답	떠올리는 경로	검산하면
3,000원	33,000 − 30,000	사과 33,000원, 합 36,000원으로 조건 불일치
16,500원	합을 반으로 나눔	차이 조건을 무시
30,000원	차이를 가격으로 오독	문제를 잘못 읽음

B집단 AI 판단 지원

> **① 1,500원을 추천합니다.**
>
> 배 상자를 x원이라 하면 사과 상자는 x + 30,000원입니다. 두 상자의 합은 2x + 30,000 = 33,000이므로 x = 1,500원입니다. 3,000원으로 생각하기 쉽지만, 그러면 사과 상자가 33,000원이 되어 두 상자의 합이 36,000원이 됩니다.

평가 문항과 연구자용 정답

번호	참가자에게 제시할 문항	정답·핵심 요소
1-a 적용 (숫자 변경)	"두 상자를 합쳐 34,000원이고, 사과 상자가 배 상자보다 31,000원 비쌉니다. 배 상자는 얼마입니까? 답과 풀이를 쓰세요."	1,500원 (유지). 2x + 31,000 = 34,000. 함정 답 3,000원
1-b 적용 (구조 변경)	"두 상자를 합쳐 33,000원이고, 사과 상자 가격은 배 상자 가격의 2배보다 3,000원 비쌉니다. 배 상자는 얼마입니까?"	10,000원 (변경). x + (2x + 3,000) = 33,000 → 3x = 30,000. 사과 23,000원
1-c 적용 (함정 없음)	"사과 상자는 30,000원이고, 두 상자를 합친 가격은 33,000원입니다. 배 상자는 얼마입니까?"	3,000원 (변경). 33,000 − 30,000. 처음 떠오른 답이 정답
1-d 설명	"원래 문제에서 배 상자가 3,000원이 아닌 이유를 수치로 설명하세요."	3,000원이면 사과 33,000원, 합 36,000원으로 합 조건과 맞지 않음
1-e 설명	"두 상자의 합은 33,000원 그대로이고, 가격 차이만 31,000원으로 커지면 배 상자 가격은 어떻게 바뀝니까? 이유와 함께 쓰세요."	1,000원으로 줄어든다. 배 상자 = (합 − 차이) ÷ 2

채점 기준

문항	2점	1점	0점
1-a	1,500원 + 식 또는 검산(사과 32,500원, 합 34,000원)	1,500원만 씀. 또는 식은 맞고 계산 실수 하나	3,000원 등 오답
1-b	10,000원 + 식(3x + 3,000 = 33,000)	10,000원만 씀. 또는 식은 맞고 계산 실수 하나	차이 문제처럼 풀어 다른 값
1-c	3,000원 + 빨셈 근거	3,000원만 씀	1,500원 등 원 문제의 풀이를 그대로 옮긴 오답

문항	2점	1점	0점
1-d	3,000원일 때 합이 36,000원이 됨을 수치로 제시	"차이를 고려해야 한다"처럼 방향만 맞음	3,000원이 맞다고 답함
1-e	줄어든다 + 1,000원 또는 (합 − 차이) ÷ 2 관계	줄어든다만 씀	늘어난다 또는 변함없다

9. 묶음 2: 비율 문제 (프린터와 전단지)

정답은 **3분**이다. 숫자가 모두 3에서 30으로 늘어나니 시간도 30분이라고 떠올리기 쉽지만, 프린터 한 대가 하는 일의 양은 변하지 않는다. CRT의 기계와 부품 문항과 같은 원리다.

원 문제 (참가자 화면)

> 프린터 3대가 3분 동안 전단지 3묶음을 인쇄합니다. 같은 프린터 30대가 전단지 30묶음을 인쇄하려면 몇 분이 걸립니까? 모든 프린터는 동시에 같은 속도로 인쇄합니다.
>
> ① 1분 ② 3분 ③ 10분 ④ 30분

연구자용 검산

프린터 1대는 3분에 1묶음을 인쇄한다. 30대가 동시에 인쇄하면 3분에 30묶음이다. 일반식: 걸리는 시간 = 묶음 수 ÷ (프린터 수 × 한 대의 분당 인쇄량).

함정 답	떠올리는 경로	검산하면
30분	숫자 3이 모두 30으로 바뀌므로 시간도 30	30대는 30분에 300묶음을 인쇄하게 됨
10분	30 ÷ 3	근거 없는 나눗셈
1분	프린터가 많으니 빨라진다	묶음 수도 같이 늘었음을 무시

B집단 AI 판단 지원

> **② 3분을 추천합니다.**
>
> 프린터 3대가 3분에 3묶음을 인쇄하므로, 프린터 1대는 3분에 1묶음을 인쇄합니다. 프린터 30대가 동시에 인쇄하면 3분 동안 30묶음을 인쇄합니다. 30분으로 생각하기 쉽지만, 프린터 수와 묶음 수가 같은 비율로 늘면 걸리는 시간은 변하지 않습니다.

평가 문항과 연구자용 정답

번호	참가자에게 제시할 문항	정답·핵심 요소
2-a 적용 (숫자 변경)	"같은 프린터 12대가 전단지 12묶음을 인쇄하려면 몇 분이 걸립니까? 답과 풀이를 쓰세요."	3분 (유지). 1대가 3분에 1묶음. 함정 답 12분
2-b 적용 (구조 변경)	"더 빠른 기종은 3대가 3분 동안 6묶음을 인쇄합니다. 이 기종 6대가 36묶음을 인쇄하려면 몇 분이 걸립니까?"	9분 (변경). 1대가 3분에 2묶음 → 6대는 3분에 12묶음 → 36묶음은 9분
2-c 적용 (함정 없음)	"원래 프린터 3대로 전단지 6묶음을 인쇄하려면 몇 분이 걸립니까?"	6분 (변경). 일의 양이 2배이고 대수는 같으므로 시간도 2배. 처음 떠오른 답이 정답
2-d 설명	"원래 문제에서 답이 30분이 아닌 이유를 설명하세요."	한 대가 3분에 1묶음을 인쇄하고, 30대가 동시에 일하므로 3분에 30묶음
2-e 설명	"인쇄할 양은 3묶음 그대로이고 프린터만 6대로 늘리면 걸리는 시간은 어떻게 바뀝니까? 이유와 함께 쓰세요."	절반(1분 30초)으로 줄어든다. 일을 나눠 맡는 프린터가 2배

채점 기준

문항	2점	1점	0점
2-a	3분 + 한 대의 인쇄량이 같다는 근거	3분만 씀. 또는 근거는 맞고 계산 실수 하나	12분 등 오답
2-b	9분 + 한 대의 인쇄량(3분에 2묶음)을 쓴 풀이	9분만 씀. 또는 풀이는 맞고 계산 실수 하나	3분(원 문제의 답을 그대로 옮김), 18분 등
2-c	6분 + 양이 2배라 시간도 2배	6분만 씀	3분 등 원 문제의 답을 그대로 옮긴 오답
2-d	한 대가 3분에 1묶음이라는 단위 인쇄량 + 30대가 동시에 인쇄함	"비율이 같다"처럼 방향만 맞음	30분이 맞다고 답함
2-e	줄어든다 + 절반(1분 30초) 또는 나눠 맡는다는 근거	줄어든다만 씀	늘어난다 또는 변함없다

10. 묶음 3: 거래 손익 문제 (중고 카메라)

정답은 **20만 원 이익**이다. 70만 원에 판 물건을 80만 원에 다시 산 것을 10만 원 손해로 세면 10만 원이 떠오르지만, 두 거래는 각각 10만 원씩 이익이다. Toplak 등(2014)이 CRT에 추가한 돼지 매매 문항과 같은 원리다.

원 문제 (참가자 화면)

> 중고 카메라를 60만 원에 사서 70만 원에 팔았습니다. 그 카메라를 다시 80만 원에 사서 90만 원에 팔았습니다. 전체 이익은 얼마입니까? 다른 비용은 없습니다.
>
> ① 0원 (손익 없음) ② 10만 원 ③ 20만 원 ④ 30만 원

연구자용 검산

들어온 돈과 나간 돈을 더하면 −60 + 70 − 80 + 90 = 20만 원이다. 거래별로 보면 첫 거래 +10, 두 번째 거래 +10이다.

함정 답	떠올리는 경로	검산하면
10만 원	팔고 다시 비싸게 산 10만 원을 손해로 셈: +10 − 10 + 10	다시 산 비용은 두 번째 거래의 구입비이며 이미 +10에 반영됨
30만 원	처음 가격과 마지막 가격만 비교: 90 − 60	중간에 더 낸 10만 원을 무시
0원	이익과 손해가 상쇄된다고 봄	손해가 난 거래가 없음

B집단 AI 판단 지원

> **③ 20만 원을 추천합니다.**
>
> 두 번의 거래를 각각 계산합니다. 첫 거래는 60만 원에 사서 70만 원에 팔아 10만 원 이익, 두 번째 거래는 80만 원에 사서 90만 원에 팔아 10만 원 이익입니다. 10만 원으로 생각하기 쉽지만, 다시 80만 원에 산 것은 손해가 아니라 두 번째 거래의 구입 비용입니다. 들어온 돈과 나간 돈으로 보아도 −60 + 70 − 80 + 90 = 20만 원입니다.

평가 문항과 연구자용 정답

번호	참가자에게 제시할 문항	정답·핵심 요소
3-a 적용 (숫자 변경)	"70만 원에 사서 80만 원에 팔고, 다시 90만 원에 사서 100만 원에 팔았습니다. 전체 이익은? 답과 풀이를 쓰세요."	20만 원 (유지). −70 + 80 − 90 + 100. 함정 답 10만 원
3-b 적용 (구조 변경)	"60만 원에 사서 70만 원에 팔고, 다시 80만 원에 사서 75만 원에 팔았습니다. 전체 이익은?"	5만 원 이익 (변경). −60 + 70 − 80 + 75. 두 번째 거래에서 손해가 남
3-c 적용 (함정 없음)	"60만 원에 사서 70만 원에 팔고, 다시 70만 원에 사서 80만 원에 팔았습니다. 전체 이익은?"	20만 원 (유지). 다시 산 가격이 판 가격과 같아 헷갈릴 지점이 없음
3-d 설명	"원래 문제에서 이익이 10만 원이 아닌 이유를 설명하세요."	두 거래가 각각 +10. 다시 산 80만 원은 손해가 아니라 두 번째 거래의 비용
3-e 설명	"원래 거래에서 두 번째로 살 때 가격만 85만 원으로 오르면 전체 이익은 어떻게 바뀝니까? 이유와 함께 쓰세요."	15만 원으로 줄어든다. 두 번째 거래의 이익이 5만 원으로 줄어듦

채점 기준

문항	2점	1점	0점
3-a	20만 원 + 거래별 이익 또는 들어온 돈·나간 돈 계산	20만 원만 씀. 또는 풀이는 맞고 계산 실수 하나	10만 원 등 오답
3-b	5만 원 이익 + 계산(+10, −5)	5만 원만 씀. 또는 풀이는 맞고 부호 실수 하나	−5만 원, 15만 원 등
3-c	20만 원 + 거래별 이익	20만 원만 씀	10만 원 등 오답
3-d	두 거래를 각각 +10으로 계산 + 다시 산 비용의 의미	"따로 계산해야 한다"처럼 방향만 맞음	10만 원이 맞다고 답함
3-e	줄어든다 + 15만 원 또는 두 번째 거래 이익이 5만 원	줄어든다만 씀	늘어난다 또는 변함없다

11. 실험 절차와 화면 원칙

참가자 한 명의 목표 소요시간은 **20~30분**이며 파일럿에서 확인한다. 예상 배분은 안내·동의·사전 질문 3분, 연습 5분, 묶음당 약 6분 × 3, 사후 질문 3분이다.

전체 순서

1. 연구 안내와 동의. "실시간 AI가 아니라 연구자가 검수한 화면을 사용한다"는 점을 여기서 밝힌다.
2. 사전 질문: 성별, 전공, AI 이용 빈도.
3. 공통 연습: 답 선택 → 확신도·적용 예상 입력 → 적용 3문항 + 설명 1문항 → 정답·풀이·채점 예시 확인 (기준 D 측정)
4. 배정된 순서의 첫 묶음: 원 문제와 배정된 지원(B는 AI 추천과 설명) 확인
5. 최초 답 선택 (4지선다)
6. 정신적 부담 평가 (1~7점)
7. AI 추천과 설명 제거 → 과제 확신도(0~100)와 예상 점수(적용 0~6, 설명 0~4) 입력
8. 적용 3문항(무작위 순서) → 설명 2문항
9. 다음 묶음 (4~8 반복)
10. 사후 질문과 짧은 인터뷰, 종료 안내

예상 점수와 확신도 질문

문제 원문만 남은 평가 준비 화면에서 세 질문을 한 화면에 함께 제시한다.

> "다음 단계에서는 AI 추천과 설명 없이 문제 원문과 계산기만 참고할 수 있습니다. 연습에서 본 방식으로 채점합니다."
>
> (1) 이와 같은 유형의 문제를, 조건이 바뀌어도 AI 없이 혼자 맞게 풀 수 있다고 얼마나 확신합니까? (0 = 전혀 확신하지 않음, 100 = 완전히 확신)
>
> (2) 조건이 바뀐 문제 3문항(6점 만점)에서 몇 점을 받을 것으로 예상합니까?
>
> (3) 원래 문제의 풀이를 설명하는 2문항(4점 만점)에서 몇 점을 받을 것으로 예상합니까?

- 확신도를 먼저 묻고 예상 점수를 나중에 묻는다. 점수를 먼저 정하면 확신도가 그 점수에 맞춰질 수 있기 때문이다.
- 예상 점수는 정수로 입력하며, 세 칸을 모두 입력해야 제출된다.
- 실제 문항은 아직 보여주지 않는다.
- 제출 후에는 수정할 수 없고, AI 설명으로 돌아갈 수 없다.
- 문제 원문은 계속 볼 수 있다.

적용 문항 표시

각 적용 문항 위에 다음 문구를 두고, 원 문제 옆에 해당 문항의 바뀐 조건을 표시한다.

> "이 문항은 원래 문제에서 출발합니다. 앞 문항의 변경 사항은 이어지지 않습니다."

정답 피드백은 전체 평가가 끝나기 전까지 제공하지 않는다.

화면과 도구 원칙

- 문제 원문은 두 집단에서 같은 위치와 형태로 제공한다. B의 추천 패널 때문에 문제가 작아지거나 가려지지 않게 한다.
- 평가에서는 원 문제와 현재 문항을 함께 볼 수 있게 한다.
- 원 문제의 4개 보기 순서는 참가자마다 섞고, 내부 보기 ID와 분리해 저장한다.
- 두 집단에 같은 사칙연산 계산기를 제공한다. 계산기는 답을 대신 구하지 않는다.
- 문항에 "함정", "주의" 같은 단서를 넣지 않는다.
- 외부 AI·검색·별도 메모 사용은 허용하지 않는다. 비대면으로 진행하면 이 점을 동의 화면에서 확인받는다.

사후 질문

- 답을 고를 때 어떤 자료나 설명을 주로 이용했는가?
- 예상 점수를 정할 때 무엇을 기준으로 했는가?
- 평가 문제를 풀 때 기억한 설명과 문제 원문을 각각 어떻게 활용했는가?
- 뒤 묶음으로 갈수록 문제를 푸는 방식이 달라졌는가? (묶음 사이 요령 전이 확인)
- 이 실험의 문제와 비슷한 문제(예: 공과 방망이 문제)를 전에 본 적이 있는가? (예 / 아니오 / 잘 모르겠다)

이 응답은 해석 보조 자료이며, 인지적 메커니즘을 확정하는 증거로 쓰지 않는다. 노출 여부는 민감도 분석에 쓴다(15장).

12. 종속변수와 공변량

주 지표는 묶음별 `D_적용`의 참가자 평균이다. 연습 과제에서 측정한 `D_기준`은 공변량으로 쓴다.

$$D_{\text{적용}} = \text{적용 예상 점수}(0\sim6) - \text{적용 실제 점수}(0\sim6)$$

- 양수: 실제보다 높게 예상 / 음수: 실제보다 낮게 예상 / 0: 점수상 일치
- 묶음별 범위는 −6~+6이다. 세 묶음을 평균하면 1/3점 단위로 더 세밀해진다.

구분	지표	측정
주 지표	D_적용	적용 예상(0~6) − 적용 실제(0~6), 세 묶음 평균
공변량	D_기준	연습 적용 예상 − 연습 적용 실제 (AI 지원 전 측정)
필수 보고	D_설명	설명 예상(0~4) − 설명 실제(0~4)
필수 해석	적용 예상, 적용 실제, 적용 절대오차	묶음별과 평균
보조	과제 자기효능감 (SE)	묶음별 확신도 0~100, 세 묶음 평균. 연습 확신도(SE_기준)는 공변량
보조	설명 실제 수행	0~4
보조	최초 선택의 정신적 부담	1~7점 한 문항
보조	최초 선택 정답 여부, 함정 답 선택 여부	묶음별
탐색	함정 없는 문항(적용 c)의 오답률	"일단 의심하는" 요령을 썼는지 확인
탐색	선택·예상·평가 시간, AI 패널 체류 시간, 문항 노출 응답	단계별 기록

읽는 법

- 절대오차(|예상 − 실제|)는 해석에 반드시 함께 제시하지만, 사후에 주 지표로 바꾸지 않는다.
- 평균 D가 0이라도 모두 정확한 것은 아니다. 과대평가와 과소평가가 상쇄될 수 있으므로 개인별 분포를 함께 본다.
- 자기효능감(확신도)은 실제 점수와 단위가 달라 그 차이로 과대·과소평가를 판단하지 않는다. 집단 평균 비교와, 집단별로 확신도가 실제 점수와 얼마나 함께 움직이는지(상관)만 본다.
- D_설명이 0에 가깝고 D_적용만 양수라면, 설명할 수 있다는 감각을 적용할 수 있다는 감각으로 일반화했을 가능성이 있다. 이 대비는 탐색적 해석으로만 제시한다.

13. 채점 운영

두 채점자가 집단 정보를 모른 채 독립적으로 채점한다. 30명 기준 채점 대상은 **540개 답변**(본 과제 450 + 연습 적용 90)이며, 이중 채점으로 1,080건이다. 정답이 숫자라 채점 부담은 교환학생 시나리오보다 크게 작다.

채점 공통 기준

점수	적용 문항	설명 문항
2점	정답 + 풀이(식, 계산, 핵심 관계 중 하나)	결론 + 수치나 관계로 된 근거
1점	정답만 쓰고 풀이가 없음, 또는 풀이는 맞고 단순 계산 실수 하나	결론(방향)만 맞고 근거가 없거나 불완전
0점	오답, 함정 답, '모르겠음'	틀린 결론, '모르겠음'
결측	기기 오류 등으로 제출되지 않음	같음

허용하는 답변 형식

짧은 문장, 간단한 식과 계산, 단위 생략('1500'), '모르겠음'. 문장력이나 길이에 점수를 주지 않으며, AI와 비슷한 표현을 썼다는 이유만으로 감점하지 않는다.

독립 채점 절차

1. 참가자 코드와 집단 정보를 분리한다.
2. 숫자 답의 정답 여부는 도구가 먼저 표시하고, 채점자는 풀이 유무와 계산 실수 여부를 판단한다.
3. 채점자에게는 문항·답변·채점표만 제공한다. AI 조건, 예상 점수, 확신도, 부담, 응답시간은 숨긴다.
4. 두 채점자가 독립적으로 채점한다.
5. 합의 전 일치도를 확인한다(가중 카파 등).
6. 불일치를 검토하고 최종 점수를 확정한다.
7. 두 원점수와 최종 점수를 모두 보존한다.

파일럿에서 자주 나타난 경계 사례를 채점표에 추가하고 본 실험 전에 고정한다. 본 실험에서 예상하지 못한 답변이 나오면 조건을 보지 않은 상태에서 같은 규칙을 전체 답변에 적용하고 변경 이력을 남긴다.

14. 표본 계획과 모집 부족 시 대응

모집 목표는 **완료 참가자 30명**(집단당 15명, 운영 조합당 5명)이고, 최소선은 24명이다. 이 연구는 효과의 방향과 크기를 추정하는 **탐색적 연구**로 설계한다. 모집이 목표에 못 미칠 때의 진행 방법은 미리 정해 두고, 결과를 본 뒤에 바꾸지 않는다.

대상은 한국어로 과제를 이해할 수 있는 대학생(19~29세)이다. 성별과 전공이 한쪽에 몰리지 않도록 모집하고, 과제 제작에 참여했거나 정답을 본 사람, 파일럿 참가자는 제외한다.

검정력

양측 α = .05, 검정력 80% 기준으로 검출 가능한 최소 효과 크기(d)는 다음과 같다. 보정 열은 D_기준과 주 지표의 상관을 r = 0.5로 가정한 근사치다.

총 인원	집단당	단순 비교	D_기준 보정 시	판단
24명	12명	d ≈ 1.20	d ≈ 1.04	최소선. 매우 큰 효과만 보임
30명	15명	d ≈ 1.06	d ≈ 0.92	목표
36명	18명	d ≈ 0.96	d ≈ 0.83	비대면을 병행할 때

중간 크기 효과(d ≈ 0.5)를 확증적으로 검출하려면 집단당 약 64명이 필요하다. 이 규모는 팀 프로젝트의 인력과 기간을 넘으므로, 결과는 p값보다 **효과 추정치와 95% 신뢰구간** 중심으로 보고한다.

인원을 늘리지 않고 정밀도를 높이는 장치

장치	효과
D_기준 공변량 보정	원래 자기평가 성향을 제거해 오차 분산을 줄임
라틴 방진 + 블록 무작위 배정	소규모에서도 집단·순서 균형 유지
세 묶음 × 적용 3문항	개인 점수의 측정 신뢰도 향상 (적용 18점 만점)
서버 자동 수집 + 비대면 병행	모집 범위 확대. 비대면은 주의 점검 문항 1개 추가

기본 모집 방법

- 대면 진행이 기본이다. 노트북·태블릿 3~4대로 동시에 진행하고 팀원 1명이 동석한다. 하루 2시간이면 약 12명을 진행할 수 있다.
- 모집 경로: 학과 단체방, 교양 수업 공지, 학내 커뮤니티, 팀원별 지인 소개. 한 학과에 몰리지 않도록 사전 질문으로 확인한다.
- 사례(예: 음료 쿠폰) 제공 여부는 모집 전에 팀에서 정한다.

단계별 대응 (사전 고정)

점검 시점	상황	대응
본 실험 시작 전 (신청 마감)	신청 24명 이상	계획대로 진행 (집단 간 설계, 대면 기본)

점검 시점	상황	대응
본 실험 시작 전	신청 16~23명	집단 간 설계를 유지하고 줌(비대면) 참여를 연다. 모집 경로를 더하고 모집 기간을 한 번(최대 1주) 연장한다. 비대면 참가자는 진행 방식을 기록해 민감도 분석에 쓴다
본 실험 시작 전	신청 16명 미만	첫 참가자를 받기 전에 아래의 집단 내 대안 설계로 전환한다
모집 마감	완료 24명 이상	계획한 확증 분석(15장)을 그대로 한다
모집 마감	완료 12~23명	같은 모형을 돌리되 추정치와 95% 신뢰구간만 보고하고 p값으로 결론을 내지 않는다. 개인별 예상-실제 그림과 사후 인터뷰 비중을 늘린다
모집 마감	완료 12명 미만	집단 비교는 기술통계만 제시한다. 참가자별 예상-실제 사례 분석과 인터뷰 질적 분석을 중심으로 한 사용성 평가 보고로 전환한다

집단 내 대안 설계 (신청 16명 미만일 때)

- 모든 참가자가 **1번째 묶음은 AI 없이, 2·3번째 묶음은 AI 지원과 함께** 푼다. AI 없는 조건을 항상 먼저 두는 이유는, AI 설명에서 배운 내용이 AI 없는 조건으로 넘어가지 않게 하기 위해서다.
- 어느 묶음이 AI 없는 조건이 될지는 라틴 방진의 3개 순서로 돌린다.
- 같은 사람의 D_적용(AI 있는 두 묶음 평균)과 D_적용(AI 없는 묶음)을 대응표본 t 검정으로 비교한다. 개인차가 빠지므로 적은 인원으로도 차이를 볼 수 있다(16명 기준 검출 가능한 $d_z \approx 0.75$).
- 한계: AI 조건이 항상 뒤에 오므로 연습·피로 효과와 AI 효과가 섞인다. 이 점을 해석에 명시하고, 집단 간 설계보다 약한 근거로 보고한다.
- 전환은 첫 참가자를 받기 전에만 한다. 이미 수집한 집단 간 자료와 섞지 않는다.

고정 원칙

- 목표 인원, 모집 기간, 위의 단계별 기준은 본 실험 시작 전에 고정한다.
- 결과의 유의성을 보면서 모집 인원을 늘리거나 종료하지 않는다.
- 주의 점검 실패, 절차 위반(외부 도구 사용 고백 등), 미완료 참가자는 사전에 정한 기준으로만 제외하고 제외 수를 집단별로 보고한다.

15. 분석 계획

확증 분석은 하나다. `D_기준`을 공변량으로 넣은 ANCOVA로 두 집단의 `D_적용` 평균을 비교한다(양측 $\alpha = .05$). 분석은 R로 한다. 모집 인원에 따라 보고 수준이 달라지는 규칙은 14장을 따른다.

주 분석

참가자 i의 주 지표는 세 묶음 평균이다.

$$\bar{D}_{\text{적용},i} = \frac{D_{\text{적용},i,1} + D_{\text{적용},i,2} + D_{\text{적용},i,3}}{3}$$

$$\bar{D}_{\text{적용},i} = \beta_0 + \beta_1 \cdot \text{집단}_i + \beta_2 \cdot D_{\text{기준},i} + \varepsilon_i$$

- 집단은 A = 0, B = 1로 코딩한다. 관심 모수는 β_1(보정된 집단 차이)이다.
- D_기준은 AI 지원 전에 측정되므로 공변량으로 쓸 수 있다.
- 이분산에 강건한 표준오차(HC3)를 쓴다.
- 보고: 집단별 원평균과 표준편차, 보정 평균, β_1과 95% 신뢰구간, 표준화 효과 크기, p값.

민감도 분석 (함께 보고)

- 공변량 없는 Welch t 검정. 두 분석의 결론이 다르면 둘 다 보고하고 차이를 논의한다.
- **첫 번째 묶음만 쓴 비교.** 묶음 사이 요령 전이가 쌓이기 전의 비교다. 세 묶음 평균과 같은 방향인지 확인한다.
- 묶음 순서를 추가한 모형(집단 + D_기준 + 순서).
- 비슷한 문제를 본 적 있다고 답한 참가자와 비대면 참가자를 각각 뺀 분석.

필수 해석 분석

`D_적용`의 차이가 어디서 왔는지 나누어 제시한다.

예상 점수	실제 점수	해석
B가 높음	비슷	지원이 예상만 끌어올림
비슷	B가 낮음	실제 수행이 낮아졌지만 예상에 반영되지 않음
B가 높음	B도 높음	실제로 배웠고 자신감도 그만큼 오름
비슷	비슷	이 과제·표본에서 뚜렷한 효과 없음

- 적용 예상, 적용 실제, 절대오차를 집단별로 각각 제시한다.
- 개인별 D_적용 분포(+, 0, − 비율)를 집단별 그래프로 제시한다.
- 적용 a·b·c 유형별 실제 점수를 집단별로 제시한다. B의 점수가 숫자 변경(a)에서만 높고 구조 변경(b)에서는 비슷하다면, 원리보다 풀이 형식을 옮긴 것으로 해석한다.
- D_설명은 같은 모형으로 추정치와 신뢰구간만 보고한다.

보조·탐색 분석

- **과제 자기효능감:** 세 묶음 평균 확신도를 SE_기준을 공변량으로 한 같은 모형으로 비교한다. 집단별로 확신도와 실제 적용 점수의 상관을 제시한다.
- **위치 효과:** D_적용 ~ 집단 × 위치 + 묶음 + D_기준 + (1 | 참가자) 혼합모형. 뒤 묶음으로 갈수록 집단 차이가 커지는지 본다.
- **함정 없는 문항(적용 c)의 오답률:** "일단 의심하고 반대로" 하는 요령을 쓴 흔적이 집단·위치별로 다른지 본다.
- 정신적 부담과 최초 선택 정답률: 보조 결과로 분석한다.
- 시간, AI 패널 체류 시간: 탐색 자료로 제시한다.
- 세 묶음을 독립된 참가자 자료처럼 분석하지 않는다.

배정 원칙

AI 집단에서 추천을 따르지 않은 참가자도 원래 집단에 포함한다(의도대로 분석). 실제 점수나 최초 정답 여부로 집단을 다시 나눠 주요 결론을 내지 않는다. 분석 전에 두 집단의 D_기준, SE_기준, AI 이용 경험, 문항 노출 비율을 비교해 배정 균형을 보고한다.

16. 파일럿과 난이도 통과 기준

파일럿은 본 실험과 별도의 참가자 6~10명으로 두 조건을 모두 포함해 진행한다. 이 자료로 효과의 유무나 크기를 판단하지 않는다. CRT형으로 바꾼 자극은 이번 파일럿이 처음이므로, 난이도와 문항 노출을 특히 확인한다.

확인 항목

항목	확인할 내용
문제의 명확성	정답이 하나이며 문장을 다르게 읽을 여지가 없는가
문항 노출	"비슷한 문제를 본 적 있다"는 응답이 얼마나 나오는가
실제 풀이 전략	원리를 사용했는가, 문항 표현이나 "함정일 것"이라는 추측을 이용했는가
설명 재현과 적용	AI 설명을 반복하는 것과 바뀐 조건에 적용하는 것이 구분되는가
문항 간 힌트	앞 문항이 뒤 문항의 정답을 알려주는가
묶음 간 요령 전이	뒤 묶음에서 "일단 의심하기"가 나타나는가
예상 점수·확신도 해석	세 칸의 의미를 이해하는가
기준 D	연습 적용 점수가 만점에 몰리지 않는가

항목	확인할 내용
채점 가능성	두 채점자가 짧은 답변도 일관되게 평가하는가
운영	20~30분 안에 진행되고, 서버에 빠짐없이 저장되는가

난이도 통과 기준 (사전 고정)

아래 기준은 **A조건(지원 없음) 참가자**에게만 적용한다. B조건 결과는 난이도 조정에 쓰지 않는다. 집단 차이를 보며 문항을 조정하는 일을 막기 위해서다.

지표	통과 기준	미달 시 조치
묶음별 적용 점수 평균	6점 만점에 2.5~4.5점	4.5 초과: 구조 변경 문항을 더 멀게 조정 / 2.5 미만: 문장 명확화
적용 만점(6점) 비율	참가자의 절반 이하	숫자·구조 조정
원 문제 정답률	20~80%	80% 초과: 소재·숫자 교체 또는 예비 묶음으로 교체 / 20% 미만: 문장 점검
함정 없는 문항(적용 c) 정답률	80% 이상	미달이면 문장이 어렵거나 함정이 숨어 있는지 점검
문항 노출 응답	"본 적 있음" 절반 미만	절반 이상인 묶음은 소재·숫자를 바꾸거나 예비 묶음으로 교체

A조건은 3~5명이므로 이 기준은 통계적 판정이 아니라 **명백한 천장·바닥을 걸러내는 점검**이다. 수정은 숫자와 소재를 바꾸는 범위에서만 하고 묶음의 원리는 바꾸지 않는다. 모든 수정은 이력으로 남기고 본 실험 전에 고정한다.

사후 인터뷰

> "이 답은 어떻게 구했나요?"
>
> "AI 설명을 그대로 떠올렸나요, 바뀐 조건으로 다시 계산했나요?"
>
> "뒤 문제로 갈수록 푸는 방식이 달라졌나요?"

문항 표현 때문에 풀렸다면 자극을 수정한다. AI 설명에서 배운 원리를 정확히 적용했다면 유효한 성과로 인정한다. 유지 문항(1-a, 2-a, 3-a, 3-c)에서 "숫자는 맞고 풀이는 없는" 답변의 비율도 센다.

AI 집단 점수가 낮아지는 문항만 골라내거나, 차이가 커질 때까지 문제를 어렵게 만들지 않는다.

17. 결과 해석과 HCI 시사점

결과 패턴별 해석

결과 패턴	가능한 해석
부담 감소, 적용 수행 향상, 오차 감소	지원이 선택 부담과 이후 수행·자기평가에 함께 도움을 줬을 가능성
부담 감소, 적용 수행 비슷, 적용 예상 상승	선택은 쉬워졌고 자기평가만 높은 방향으로 이동
B의 적용 수행이 더 낮지만 예상은 비슷하거나 높음	낮아진 독립 수행이 자기평가에 반영되지 않았을 가능성
적용 수행과 예상이 함께 낮음	낮은 수행 가능성을 어느 정도 인식했을 가능성
뚜렷한 집단 차이 없음	이 과제·표본에서 명확한 효과를 확인하지 못함 (효과 없음을 뜻하지 않음)

'비슷함'은 유의하지 않다는 이유만으로 동등하다고 확정하지 않는다. 차이의 추정치와 신뢰구간을 함께 본다.

주장하지 않는 것

- AI가 지능이나 장기 능력을 저하시킨다.
- AI가 인간의 사고를 대체했다.
- 반복 사용이 의존을 만든다.
- 전문가 수준 과제나 AI가 틀리는 상황에서도 같은 효과가 나타난다.
- CRT형 문제의 결과가 실제 의사결정 전반에 그대로 일반화된다.
- 특정 UX 기능을 추가하면 문제가 해결된다.

한계

- 추천과 설명을 함께 제공하므로, 둘 중 무엇이 효과를 냈는지 분리하지 못한다.
- AI는 항상 정확하다. AI가 틀리는 상황의 자기평가는 다루지 않는다.
- CRT형 문제는 퍼즐에 가까워, 여러 조건을 비교해 고르는 실제 AI 사용 장면과 거리가 있다.
- 묶음의 원리는 다르지만 '함정이 있을 수 있다'는 감은 뒤 묶음으로 넘어갈 수 있다. 첫 묶음 비교와 위치 효과 분석으로 확인한다.
- CRT 원리를 아는 참가자가 있을 수 있다. 노출 응답을 기록해 민감도 분석으로 확인한다.
- 표본이 작아 중간 크기 효과는 확증하기 어렵다.

HCI 시사점

이 연구는 **추천과 설명을 제공하는 판단 지원 인터페이스의 이익과 한계**를 평가한다. 실제 수행에 비해 높은 자기평가가 나타난다면, 사용자가 추천을 쉽게 받아들였다는 사실만으로 자신의 독립 수행 범위까지 적절히 파악한다고 가정하기 어렵다는 시사점을 줄 수 있다. 반대로 수행이 향상되고 자기평가도 적절해진다면, 조건을 정확히 연결하는 설명이 사용자에게 유용한 지원일 수 있음을 보여준다.

핵심 조건 확인, 짧은 적용 점검, 자기 설명 기능, 사용자가 스스로 답을 정한 뒤에만 AI를 요청하게 하는 방식(Nair et al., 2025) 등은 후속 디자인으로 제안할 수 있지만, 이번 실험에서 검증한 개선책으로 소개하지 않는다.

18. 실험 도구(HTML + 서버) 구현 항목

기존 파일럿 HTML(v1.1, 교환학생 시나리오)의 화면 흐름은 그대로 쓰고, 문항 데이터와 입력 항목을 바꾼다. 응답은 서버에 자동으로 수집한다.

우선순위	구현 항목
필수	연습·세 묶음의 문제·보기·AI 추천과 설명·문항·정답·채점표를 이 문서(7~10장)와 일치
필수	라틴 방진 3개 순서 × 2집단 = 6조합 블록 무작위 배정표, 참가자 순번에 따른 자동 배정 (현재 6개 순서 방식에서 변경)
필수	원 문제는 4지선다, 보기 순서를 참가자마다 섞고 내부 보기 ID와 분리 저장
필수	AI 설명 제거 후 확신도(0~100) → 적용 예상(0~6) → 설명 예상(0~4) 입력, 세 칸 모두 입력해야 제출, 제출 후 수정·AI 설명 재열람 차단
필수	적용 3문항의 제시 순서를 무작위로 섞고, 설명 2문항은 그 뒤에 제시
필수	연습: 확신도·적용 예상 입력 → 적용 3 + 설명 1 → 제출 후에만 정답·풀이·채점 예시 표시. 연습 적용 답변도 채점 파일에 포함
필수	적용 문항마다 "원래 문제에서 출발" 문구와 바뀐 조건 표시, 정답 피드백은 전체 종료 전까지 숨김
필수	공통 사칙연산 계산기 (달력은 제거)
필수	서버 저장: 사전 질문, 묶음별 최초 선택·부담·확신도·pred_apply(0~6)·pred_explain(0~4)·문항별 답변, 연습의 확신도·pred_apply·적용 답변, 사후 질문(문항 노출 응답 포함), 진행 방식(대면/비대면)과 기기

우선순위	구현 항목
필수	네트워크가 끊겨도 응답을 잃지 않도록 브라우저에 임시 저장했다가 다시 전송. 연구자용 JSON·CSV 내보내기도 유지
필수	채점용 내보내기: 집단·예상 점수·확신도 없이 문항과 답변만 포함, 숫자 답의 정답 여부를 미리 표시
필수	채점자 1·채점자 2·최종 점수 구분 저장, 적용·설명 소계 계산
필수	미채점·결측·모르겠음 상태 구분, 중단·재개
필수	집단 내 대안 설계(14장)로 전환할 경우를 대비해, 묶음별 AI 제공 여부를 설정으로 바꿀 수 있게 함
권장	단계별·문항별 시간과 AI 패널 체류 시간 기록
권장	비대면 진행 시 주의 점검 문항 1개, 외부 도구 미사용 확인

부록 A. 검산 기록

연습과 세 묶음의 모든 정답을 Python(분수 계산)으로 확인했다.

과제	문항	계산	정답	함정 답
연습	원 문제 (6km/3km)	2 ÷ (1/6 + 1/3)	4km	4.5km
연습	P-1 (12km/4km)	2 ÷ (1/12 + 1/4)	6km	8km
연습	P-2 (5km/5km)	2 ÷ (1/5 + 1/5)	5km	—
연습	P-3 (1시간씩)	(6 + 3) ÷ 2	4.5km	4km
1 차 이	원 문제	(33,000 − 30,000) ÷ 2	1,500원	3,000원
1 차 이	1-a	(34,000 − 31,000) ÷ 2	1,500원	3,000원
1 차 이	1-b	(33,000 − 3,000) ÷ 3, 사과 23,000원	10,000 원	—
1 차 이	1-c	33,000 − 30,000	3,000원	1,500원 (원 풀이 옮김)
1 차 이	1-e	(33,000 − 31,000) ÷ 2	1,000원	—

과제	문항	계산	정답	함정 답
2 비율	원 문제	30 ÷ (30 × 1/3)	3분	30분
2 비율	2-a	12 ÷ (12 × 1/3)	3분	12분
2 비율	2-b	36 ÷ (6 × 2/3)	9분	3분 (원 답 옮김)
2 비율	2-c	6 ÷ (3 × 1/3)	6분	3분 (원 답 옮김)
2 비율	2-e	3 ÷ (6 × 1/3)	1.5분	—
3 손익	원 문제	−60 + 70 − 80 + 90	20만 원	10만 원
3 손익	3-a	−70 + 80 − 90 + 100	20만 원	10만 원
3 손익	3-b	−60 + 70 − 80 + 75	5만 원	—
3 손익	3-c	−60 + 70 − 70 + 80	20만 원	—
3 손익	3-e	−60 + 70 − 85 + 90	15만 원	—
예비	2배 증가 (40일째 도달, 절반은?)	40 − 1	39일째	20일째

검산은 정답의 정확성만 보장하며, 함정 답의 작동과 난이도는 파일럿에서 확인한다. 비율 묶음의 1/3은 '한 대가 1분에 인쇄하는 묶음 수'다.

부록 B. 참고문헌

- Bandura, A. (1977). Self-efficacy: Toward a unifying theory of behavioral change. Psychological Review, 84(2), 191–215.
- Bandura, A. (2006). Guide for constructing self-efficacy scales. In F. Pajares & T. Urdan (Eds.), Self-efficacy beliefs of adolescents (pp. 307–337). Information Age Publishing.
- Bansal, G., Wu, T., Zhou, J., Fok, R., Nushi, B., Kamar, E., Ribeiro, M. T., & Weld, D. (2021). Does the whole exceed its parts? The effect of AI explanations on complementary team performance. CHI 2021.

- Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, Ö., & Mariman, R. (2025). Generative AI without guardrails can harm learning: Evidence from high school mathematics. PNAS, 122(26), e2422633122. doi
- Bialek, M., & Pennycook, G. (2018). The cognitive reflection test is robust to multiple exposures. Behavior Research Methods, 50, 1953–1959. doi
- Buçinca, Z., Malaya, M. B., & Gajos, K. Z. (2021). To trust or to think: Cognitive forcing functions can reduce overreliance on AI in AI-assisted decision-making. Proc. ACM Hum.-Comput. Interact., 5(CSCW1).
- Chromik, M., Eiband, M., Buchner, F., Krüger, A., & Butz, A. (2021). I think I get your point, AI! The illusion of explanatory depth in explainable AI. IUI 2021, 307–317. doi
- De Neys, W., Rossi, S., & Houdé, O. (2013). Bats, balls, and substitution sensitivity: Cognitive misers are no happy fools. Psychonomic Bulletin & Review, 20(2), 269–273.
- Fernandes, D., Villa, S., Nicholls, S., Haavisto, O., Buschek, D., Schmidt, A., Kosch, T., Shen, C., & Welsch, R. (2026). AI makes you smarter but none the wiser: The disconnect between performance and metacognition. Computers in Human Behavior, 175, 108779. doi
- Fisher, M., Goddu, M. K., & Keil, F. C. (2015). Searching for explanations: How the Internet inflates estimates of internal knowledge. Journal of Experimental Psychology: General, 144(3), 674–687.
- Frederick, S. (2005). Cognitive reflection and decision making. Journal of Economic Perspectives, 19(4), 25–42.
- Gajos, K. Z., & Mamykina, L. (2022). Do people engage cognitively with AI? Impact of AI assistance on incidental learning. IUI 2022. arXiv
- Nair, P. P. M., Gressel, G., Anand, M. N., & Achuthan, K. (2025). To solicit or not to solicit? Impact of AI assistance delivery mechanisms on decision-making. International Journal of Human–Computer Interaction. doi
- Rozenblit, L., & Keil, F. (2002). The misunderstood limits of folk science: An illusion of explanatory depth. Cognitive Science, 26(5), 521–562.
- Schraw, G. (2009). A conceptual analysis of five measures of metacognitive monitoring. Metacognition and Learning, 4(1), 33–45.
- Toplak, M. E., West, R. F., & Stanovich, K. E. (2014). Assessing miserly information processing: An expansion of the Cognitive Reflection Test. Thinking & Reasoning, 20(2), 147–168.
- Vasconcelos, H., Jörke, M., Grunde-McLaughlin, M., Gerstenberg, T., Bernstein, M. S., & Krishna, R. (2023). Explanations can reduce overreliance on AI systems during decision-making. Proc. ACM Hum.-Comput. Interact., 7(CSCW1).

링크가 없는 문헌의 권호와 쪽수는 기억에 의존했으므로 제출 전에 DOI로 확인한다.